

Manual de conexión — Base de datos DuckDB

VisaPredict AI · panel multiserie y(p,c,b,t)

Este manual reúne **todas las formas de consultar** el almacén DuckDB del proyecto: desde Python, la línea de comandos, la interfaz web oficial y dos aplicaciones de escritorio. Elige la que más te acomode; todas leen el **mismo archivo**.

1. La base de datos

Archivo	data/processed/visapredict.duckdb (≈ 11 MB)
Ruta absoluta	/Users/haowei/Documents/Anteproyecto/VisaPredictAI/data/processed/visapredict.duckdb
Contenido	11 tablas + 6 vistas/marts (esquema estrella)
Fuente de verdad	data/processed/visa_panel_long.csv (versionado en git)
El .duckdb	derivado y regenerable — está en .gitignore
Regenerar	make db (corre build_database.py)

El .duckdb y el .parquet se reconstruyen de cero con make db. Si los borras o corrompes, no pasa nada. **Nunca edites la base a mano**: cambia el scraper o el CSV.

2. Reglas importantes antes de conectar

Regla del candado (un solo escritor). DuckDB permite **un solo proceso con el archivo abierto en escritura** a la vez. Varios procesos pueden abrirlo en **solo-lectura** simultáneamente, pero entonces ninguno puede escribir.

- Para **explorar**, abre siempre en **solo-lectura** (read-only). Así nunca chocas con `make db` ni con otra app.
- **No** tengas dos herramientas en modo escritura sobre el archivo al mismo tiempo.
- Antes de correr `make db`, cierra las apps/UI que tengan la base abierta (o ábrelas read-only).

3. Formas de conexión

Método	Tipo	Requiere instalar	Mejor para
A. Python (venv <code>ante</code>)	Script / REPL	Nada (ya está)	Automatizar, scripts
B. DuckDB CLI	Terminal	<code>brew install duckdb</code>	Consultas rápidas
C. DuckDB Web UI	Navegador (oficial)	Nada extra (usa el CLI/módulo)	Explorar + gráficas
D. TablePlus	App nativa Mac	<code>brew install --cask tableplus</code>	Navegar, exportar
E. DBeaver	App nativa (Java)	<code>brew install --cask dbeaver-community</code>	Multi-BD
F. VS Code	Editor	Extensión "DuckDB"	Quedarte en el editor

A. Python (ya instalado en el venv `ante`)

El módulo `duckdb` ya está en el entorno. Una consulta rápida:

```
cd /Users/haowei/Documents/Anteproyecto/VisaPredictAI
source ante/bin/activate
```

```
python -c "import duckdb;
print(duckdb.connect('data/processed/visapredict.duckdb',
read_only=True).execute('SELECT * FROM mart_series_summary
LIMIT 10').fetchdf())"
```

En un script:

```
import duckdb
con = duckdb.connect("data/processed/visapredict.duckdb",
read_only=True)
df = con.execute("SELECT * FROM mart_training_F WHERE
country='mexico'").fetchdf()
print(df)
con.close()
```

Usa siempre `read_only=True` para consultar; evita bloquear el archivo.

B. DuckDB CLI (terminal)

Instalar una sola vez:

```
brew install duckdb
```

Abrir un shell SQL interactivo:

```
cd /Users/haowei/Documents/Anteproyecto/VisaPredictAI
duckdb -readonly data/processed/visapredict.duckdb
```

Comandos útiles dentro del shell:

```
.tables          -- lista tablas y vistas
.schema fact_priority -- ver el DDL de una tabla
.mode box        -- salida en cajas bonitas
SELECT * FROM mart_series_summary LIMIT 10;
.quit
```

Una sola consulta sin entrar al shell:

```
duckdb data/processed/visapredict.duckdb -c "SELECT country, count(*)
FROM mart_series_summary GROUP BY 1"
```

C. DuckDB Web UI (navegador) — la interfaz oficial

Es un servidor local que se ve en el navegador (`http://localhost:4213`). No sube nada a la nube. La forma directa, teniendo el CLI:

```
cd /Users/haowei/Documents/Anteproyecto/VisaPredictAI
duckdb -ui data/processed/visapredict.duckdb
```

Para que conviva con otra app abierta (p. ej. TablePlus en read-only), lánzala adjuntando la base en solo-lectura — así ningún proceso bloquea al otro:

```
cd /Users/haowei/Documents/Anteproyecto/VisaPredictAI
source ante/bin/activate
python -c "import duckdb,time; c=duckdb.connect(); c.execute(\"ATTACH
'data/processed/visapredict.duckdb' AS visapredict
(READ_ONLY)\"); c.execute('CALL start_ui()');
time.sleep(43200)\""
```

Dentro de la UI, la base aparece como **visapredict** en el panel izquierdo. En una celda SQL, fíjala como activa y luego consulta normal:

```
USE visapredict;
SELECT * FROM mart_series_summary ORDER BY n_trainable DESC LIMIT 25;
```

En la web UI: clic en una columna te da estadísticas y distribución; los resultados se pueden ver como **gráfica** sin escribir código.

D. TablePlus (app nativa de Mac)

Instalar una sola vez:

```
brew install --cask tableplus
```

1. Abre TablePlus → **Create Connection** → elige **DuckDB**.
2. Llena:
 - **Name:** VisaPredict
 - **Database path:** la ruta absoluta del archivo (ver sección 1), o usa “Select file...”.
 - **Read Only:** déjalo **activado** (recomendado).
3. **Test** → **Connect**.

TablePlus trae DuckDB nativo (no descarga drivers). La versión gratuita basta para explorar (limita a ~2 pestañas a la vez).

E. DBeaver Community (app nativa, multi-BD)

Instalar una sola vez:

```
brew install --cask dbeaver-community
```

1. **Nueva conexión** (icono enchufe “+”) → busca **DuckDB** → Next.
2. **Path**: la ruta absoluta del archivo (sección 1).
3. La primera vez, DBeaver pide **descargar el driver de DuckDB** → *Download*.
4. Marca la conexión como **Read-only** (pestaña *Connection details*).
5. *Finish* y explora.

Si DBeaver da error de **versión** (“incompatible storage / newer version”), el driver es más viejo que el archivo (creado con DuckDB 1.5.3). Ve a *Database* → *Driver Manager* → *DuckDB* → *Edit* → *Libraries* y baja el driver $\geq 1.5.3$.

F. VS Code (extensión)

Si ya usas VS Code: abre **Extensiones** (Cmd+Shift+X), busca “**DuckDB**” e instala una. Te deja correr SQL contra el archivo `.duckdb` sin salir del editor.

4. Consultas de arranque

El repo incluye `docs/example_queries.sql` con 14 consultas validadas (el panel, el set entrenable, Diversity Visa, linaje de etiquetas, jerarquía, retrogresiones...). Ábrelo en cualquiera de las herramientas y corre las que quieras.

Desde el CLI puedes correr todo el archivo de un jalón:

```
duckdb -readonly data/processed/visapredict.duckdb < docs/example_queries.sql
```

5. Catálogo rápido

Vistas y marts (lo más útil para consultar):

Vista	Qué da
<code>v_panel_long</code>	El panel tidy completo y(p,c,b,t) (reconstrucción sin pérdida del CSV)
<code>mart_training_F</code>	Solo lo entrenable (estado F) con la variable dependiente
<code>mart_series_summary</code>	Resumen por serie (para filtrar las “evaluables”)
<code>v_dv_long</code>	Diversity Visa (rango regional; dataset aparte, no objetivo predictivo)
<code>v_category_alias</code>	Linaje: qué etiquetas crudas se volvieron cada categoría canónica
<code>v_trainable_by_preference</code>	Roll-up por nivel de preferencia (EB-5 plegado)

Tablas base: `dim_area`, `dim_category`, `dim_table`, `dim_date`, `dim_status`, `dim_region`, `dim_category_alias`, `fact_priority`, `fact_dv_rank`, `schema_version`, `etl_run`.

6. Solución de problemas

Síntoma	Causa	Solución
<code>Could not set lock / database is locked</code>	Otra app/proceso tiene el archivo en escritura	Cierra esa app, o abre todo en read-only
Catalog <code>"_duckdb_ui"</code> does not exist	Abriste la Web UI en read-only (no puede crear su estado)	Ábrela en read-write, o adjunta la base read-only (sección C)
DBeaver: error de versión / storage	Driver de DuckDB más viejo que 1.5.3	Actualiza el driver a $\geq 1.5.3$ (Driver Manager)
Puerto 4213 ocupado	Quedó una Web UI corriendo	<code>lsof -ti tcp:4213 \\\nxargs kill</code>
La base “desapareció”	Borraste el <code>.duckdb</code> (es regenerable)	<code>make db</code> la reconstruye

*Generado para el repositorio VisaPredict AI. La base es un artefacto de datos;
las cifras no constituyen asesoría legal.*